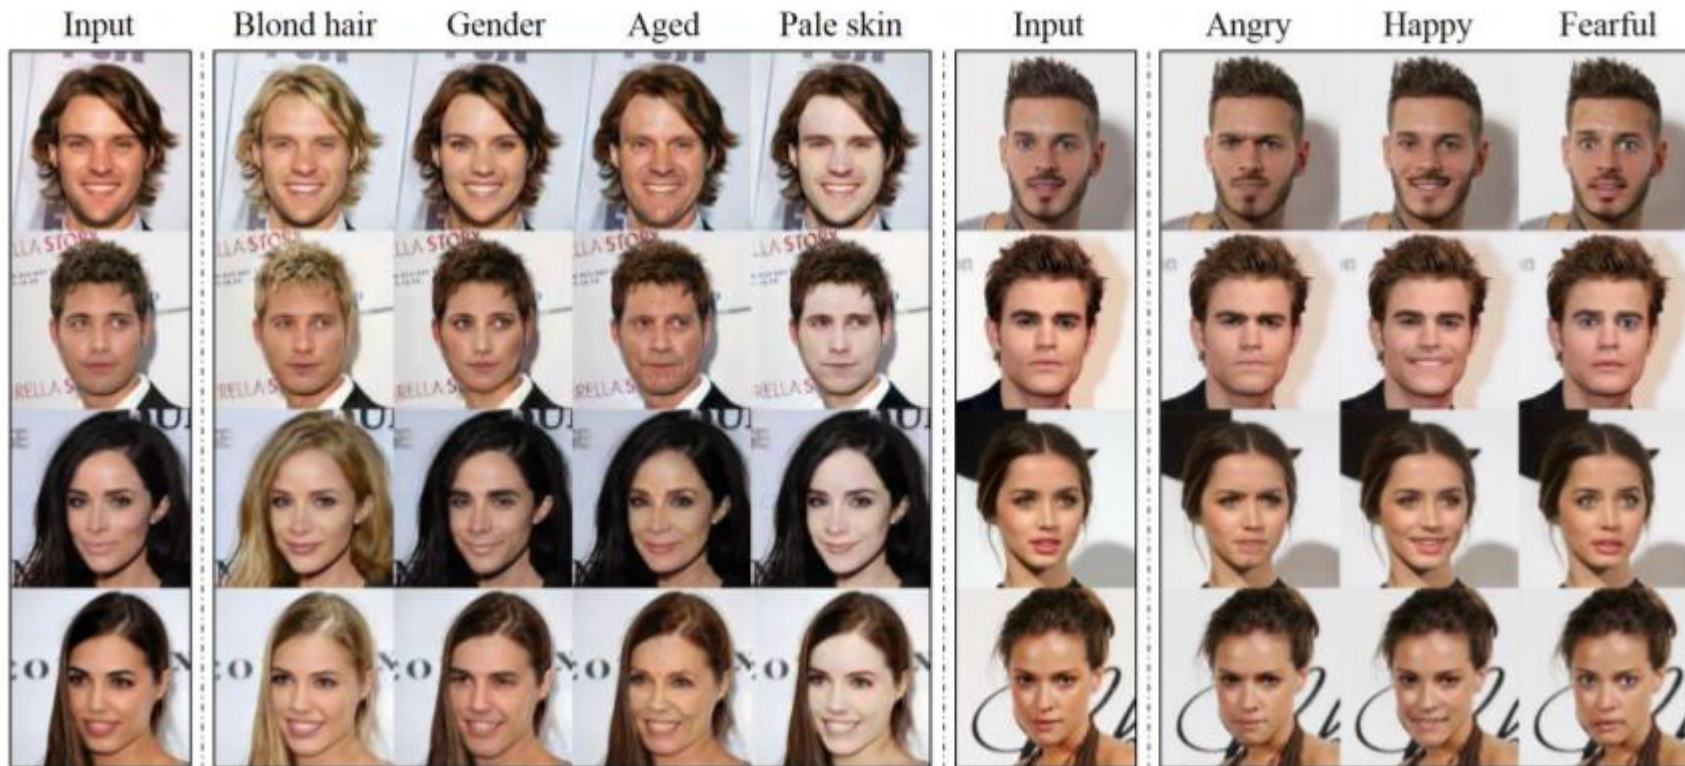


생성적 적대 신경망(GAN)



GAN (Generative Adversarial Network)

GAN은 적대 관계를 가지고 서로 경쟁하는 2개의 딥러닝 모델을 사용합니다.



생성자는 위조 이미지를 만들고 판별자는 위조 이미지와 진짜 이미지를 구분합니다..

훈련이 계속됨(적대 상호 작용)에 따라 판별자뿐만 아니라 사람이 보아도 그럴싸한 가짜를 만드는 생성자가 됩니다.

생성자(Generator)

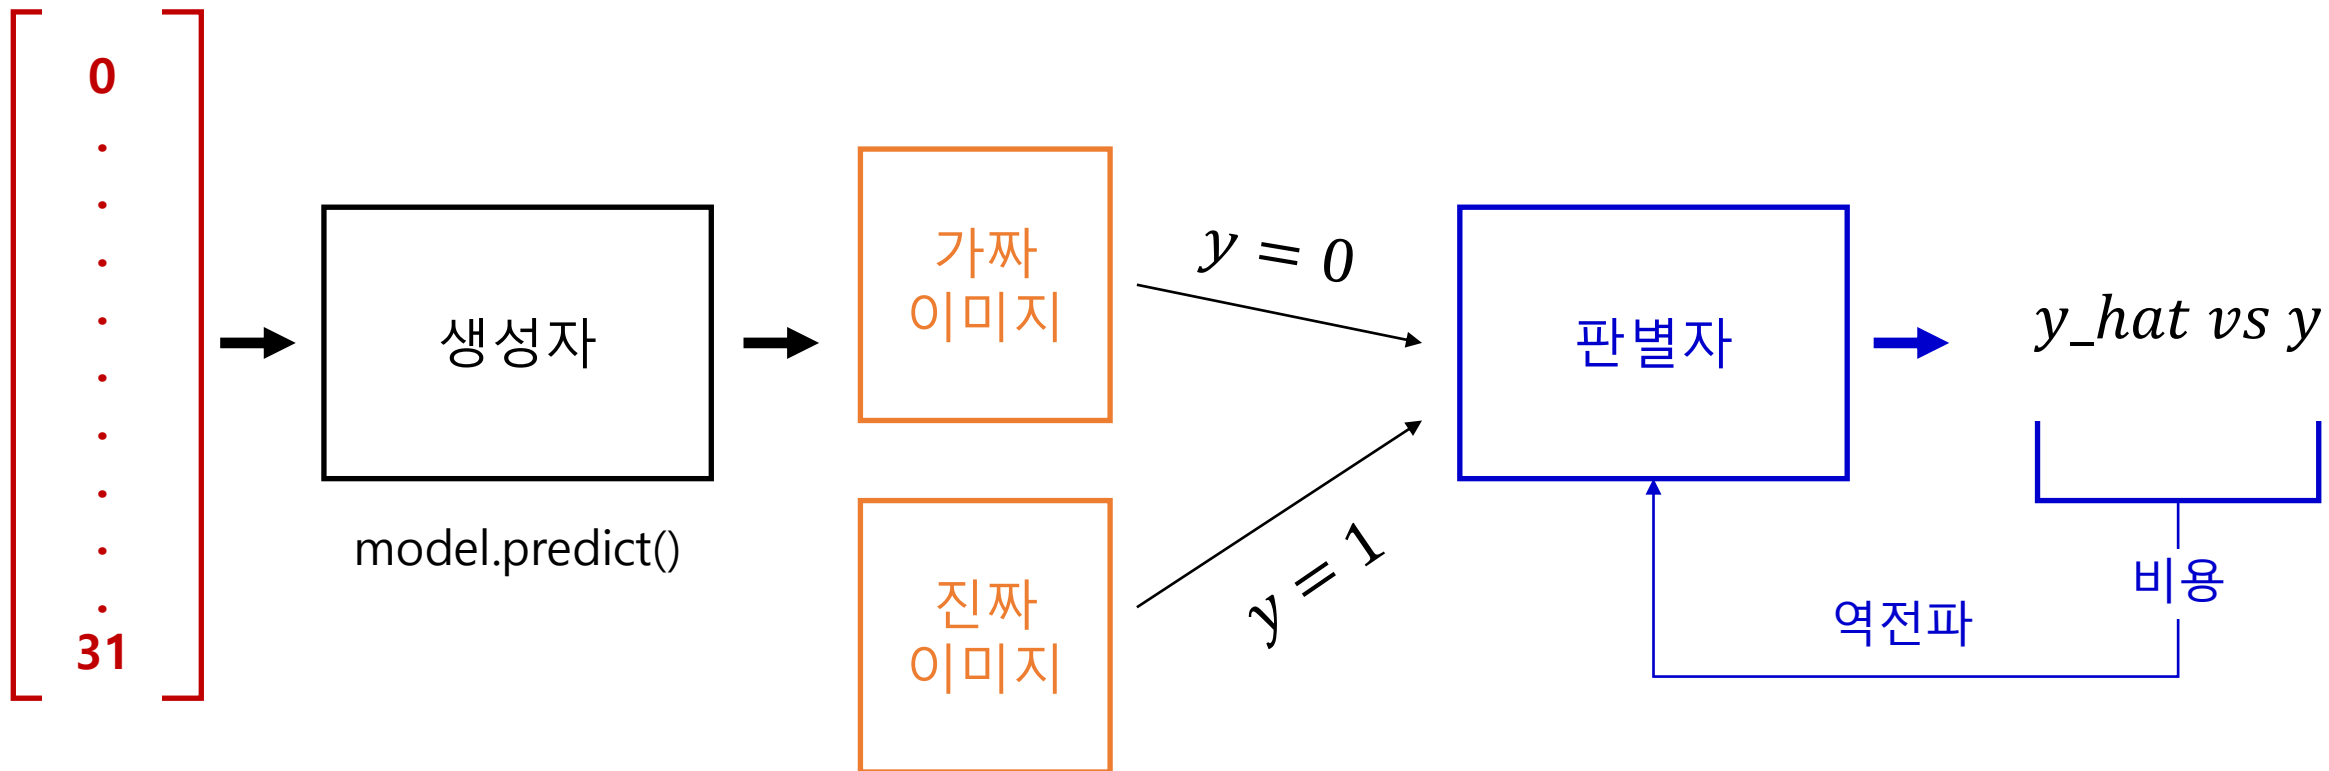
판별자(Discriminator)

$\begin{bmatrix} 0 \\ \vdots \\ 31 \end{bmatrix}$



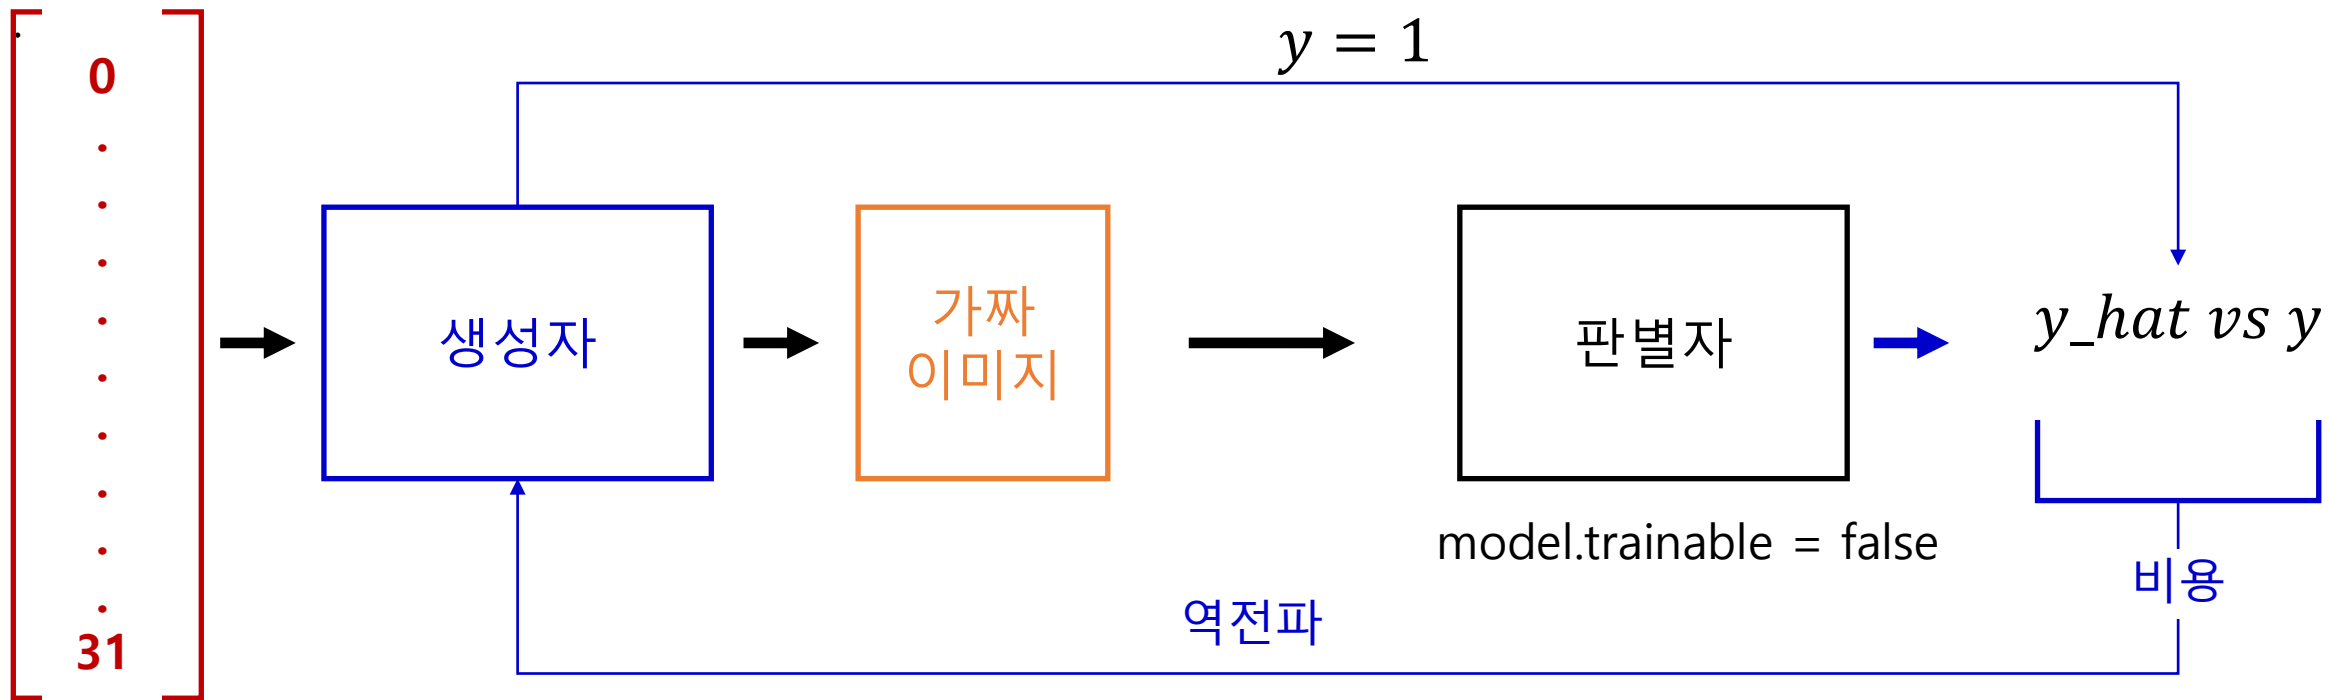
판별자 훈련

- 생성자의 정방향 계산으로 가짜 이미지를 만듭니다.
- 생성된 가짜 이미지와 진짜 이미지를 섞어 배치를 만들고, 레이블을 더해 판별자를 훈련합니다.
- 판별자는 이미지가 진짜일 가능성에 해당하는 예측($y_{\hat{}}$)을 출력합니다.
- 판별자의 예측 $y_{\hat{}}$ 과 진짜 레이블 y 에 대한 손실을 계산합니다.
- 역전파로 판별자의 파라미터를 튜닝합니다.




생성자 훈련

- 생성자는 랜덤한 잡음 벡터 z 를 입력으로 받고 가짜 이미지를 만듭니다.
- 생성자가 만든 가짜 이미지를 판별자로 주입합니다. 가짜 이미지의 레이블을 모두 진짜($y=1$)로 입력합니다.
- 판별자는 입력 이미지가 진짜인지 가짜인지에 대한 예측 $y_{\hat{}}$ 을 출력합니다.
- 크로스-엔트로피 손실을 사용해 생성망 신경망의 파라미터를 튜닝합니다.
- 생성자는 판별자가 속을 만한 가짜 이미지를 만드는 방법을 학습합니다.
- 이 비용을 최소화하면 판별자가 진짜로 잘못 판단할 가짜 이미지를 만들도록 생성자가 학습이 될 것입니다.



GAN 구현 실습 - Quick draw

<https://github.com/googlecreativelab/quickdraw-dataset>



Key	Type	Description
key_id	64-bit unsigned integer	A unique identifier across all drawings.
word	string	Category the player was prompted to draw.
recognized	boolean	Whether the word was recognized by the game.
timestamp	datetime	When the drawing was created.
countrycode	string	A two letter country code (ISO 3166-1 alpha-2) of where the player was located.
drawing	string	A JSON array representing the vector drawing

GAN 구현 실습 - Quick draw



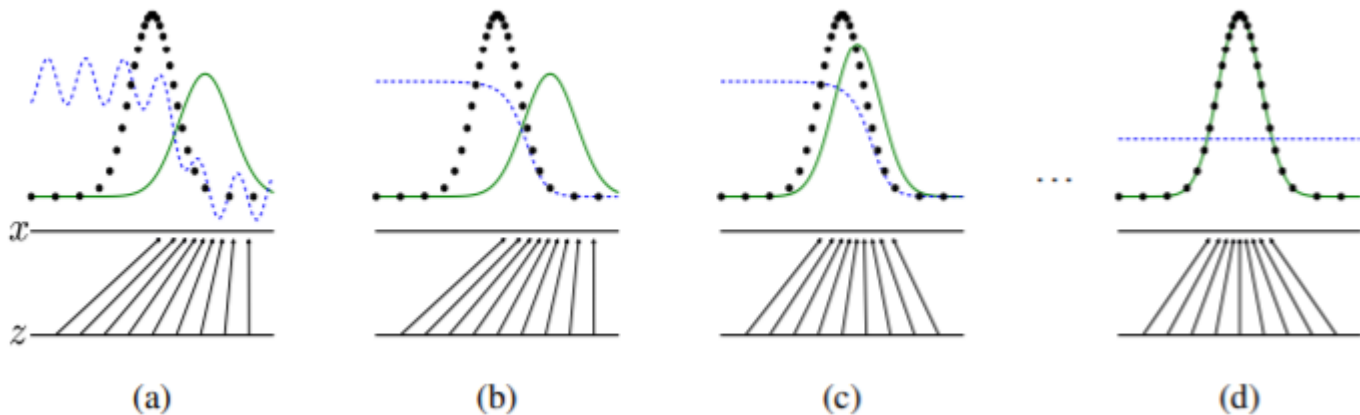
`generative_adversarial_network.ipynb`

GAN 모델

<https://ysbsb.github.io/gan/2020/06/17/GAN-newbie-guide.html>

Generative Adversarial Nets [NIPS 2015]

- Ian Goodfellow가 최초로 GAN (Generative Adversarial Nets)를 제안한 논문.
- 새로운 이미지를 생성하는 생성자 Generator와 샘플 데이터와 생성자가 생성한 이미지를 구분하는 구별자 Discriminator 두 개의 네트워크 구조를 제안함.
- 생성자는 구별자를 속이면서 이미지를 잘 생성하려고 하며, 구별자는 주어진 이미지와 진짜인지 가짜인지 판별함.



a)



b)



c)




d)

GAN 모델

<https://ysbsb.github.io/gan/2020/06/17/GAN-newbie-guide.html>

Unsupervised Representation Learning with Deep Convolutional Generative Adversarial Networks [ICLR 2016]

- 기존의 GAN에 CNN의 네트워크를 도입한 DCGAN (Deep Convolutonal Generative Adversarial Networks) 를 제안함.
- Supervised learning에서 CNN이 큰 역할을 하고 있는데, unsupervised learning에서는 CNN이 주목을 덜 받고 있었음.
- 이렇게 CNN에서 성공적인 점을 GAN에도 적용하여 기존 GAN보다 훨씬 좋은 성능을 내게 되었음. 그 전까지 GAN만 사용하면 성능이 좋지 않았으나, DCGAN 이후로부터 GAN의 발전이 많이 되었음.



GAN 모델

<https://ysbsb.github.io/gan/2020/06/17/GAN-newbie-guide.html>

Image-to-Image Translation with Conditional Adversarial Networks (Pix2Pix) [CVPR 2017]

- 입력 이미지와 출력 이미지를 맵핑하는 것을 학습할 뿐만 아니라, 이 맵핑을 train 하기 위한 loss function도 학습을 함. CNN에서 사용하는 Euclidean distance를 사용하면 blurry한 결과가 생성됨.

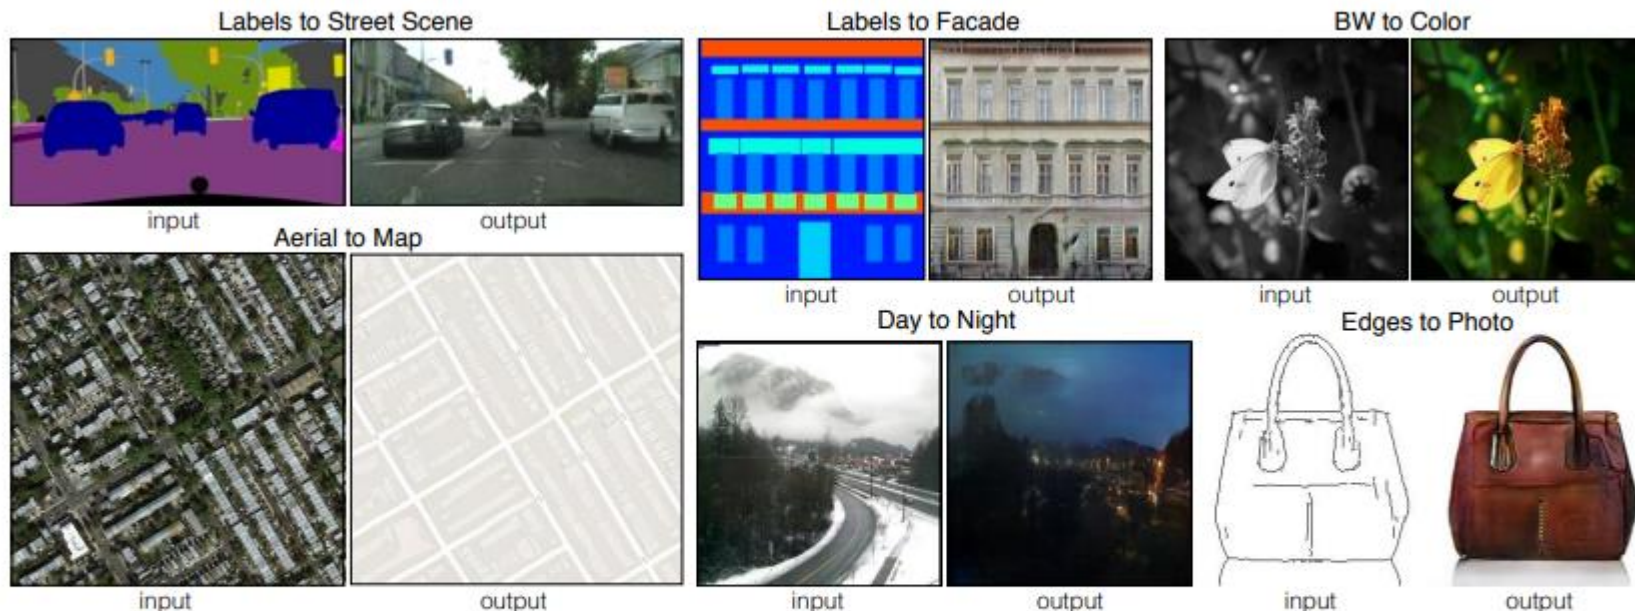


Figure 1: Many problems in image processing, graphics, and vision involve translating an input image into a corresponding output image. These problems are often treated with application-specific algorithms, even though the setting is always the same: map pixels to pixels. Conditional adversarial nets are a general-purpose solution that appears to work well on a wide variety of these problems. Here we show results of the method on several. In each case we use the same architecture and objective, and simply train on different data.

GAN 모델

<https://ysbsb.github.io/gan/2020/06/17/GAN-newbie-guide.html>

StarGAN: Unified Generative Adversarial Networks for Multi-Domain Image-to-Image Translation [CVPR 2018]

- 기존의 연구들에서 두 개의 도메인의 image-to-image translation의 성공을 보여줌.
- 하지만, 기존의 접근법들은 두 개 이상의 도메인에 대해 다루기 어렵고, 모든 이미지 도메인의 짝마다 독립적으로 다른 모델들을 생성해야 함.
- StarGAN은 이런 한계를 극복하고, 오직 하나의 모델만 가지고 다양한 데이터셋에서 다양한 도메인을 위한 image-to-image translation을 수행할 수 있음.

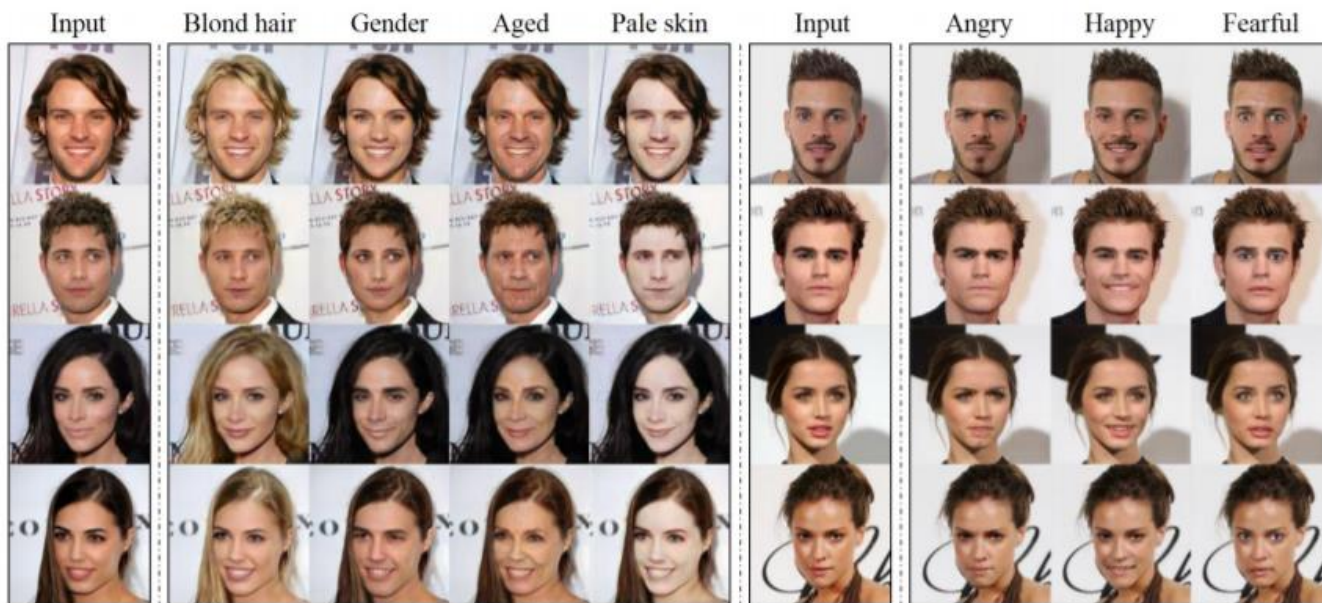


Figure 1. Multi-domain image-to-image translation results on the CelebA dataset via transferring knowledge learned from the RaFD dataset. The first and sixth columns show input images while the remaining columns are images generated by StarGAN. Note that the images are generated by a single generator network, and facial expression labels such as angry, happy, and fearful are from RaFD, not CelebA.




Figure 2. Comparison between cross-domain models and our proposed model, StarGAN. (a) To handle multiple domains, cross-domain models should be built for every pair of image domains. (b) StarGAN is capable of learning mappings among multiple domains using a single generator. The figure represents a star topology connecting multi-domains.

GAN 모델

<https://ysbsb.github.io/gan/2020/06/17/GAN-newbie-guide.html>

Photo-Realistic Single Image Super-Resolution Using a Generative Adversarial Network

- 기존 이미지 Super-Resolution 문제에서 정확도와 스피드 측면에서 많은 발전을 이루었지만, 질감의 디테일을 어떻게 회복시킬 것인지에 대한 문제가 있었음.
- Loss로 MSE loss를 사용하는데 PSNR ratio는 높지만 고해상도에서 high-frequency detail이 떨어짐. SRGAN은 이러한 문제를 해결하기 위한 Super Resolution 문제에 대한 GAN 네트워크를 처음 제시함.




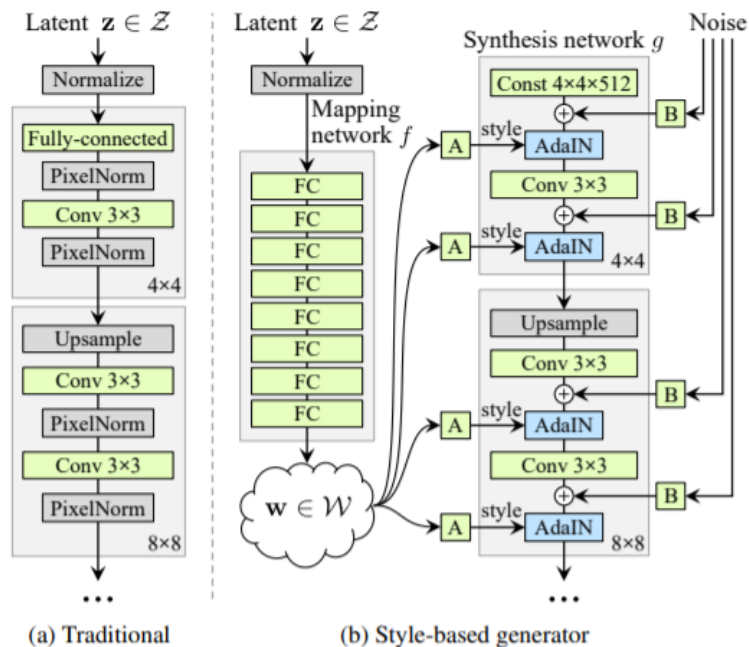
Figure 2: From left to right: bicubic interpolation, deep residual network optimized for MSE, deep residual generative adversarial network optimized for a loss more sensitive to human perception, original HR image. Corresponding PSNR and SSIM are shown in brackets. [4× upscaling]

GAN 모델

<https://ysbsb.github.io/gan/2020/06/17/GAN-newbie-guide.html>

A Style-Based Generator Architecture for Generative Adversarial Networks (StyleGAN) [CVPR 2019]

- Generator 네트워크에서 각 레이어마다 스타일 정보를 입히는 방식으로 학습함.
- 이미지의 스타일 (성별, 포즈, 머리색, 피부톤 등)을 변경할 수 있음.
- Latent vector z 는 특정 데이터셋의 분포를 그대로 따라가는 경향이 있는데, 이를 보완하기 위해서 그대로 사용하는 것이 아니라 Mapping network를 만들어서 나온 w vector를 활용하여 스타일을 더 다양하게 바꿀 수 있도록 함.



DCGAN (Deep Convolutional Generative Adversarial Networks) 구현 실습



<https://www.tensorflow.org/tutorials/generative/dcgan?hl=ko>

Thank you